Localización de oficinas y reequilibrio territorial en los 179 municipios de la Comunidad de Madrid

Madrid 179 es una herramienta de apoyo a la decisión para dos públicos. Las **empresas y emprendedores** buscan dónde abrir o trasladar una oficina dentro de los 179 municipios de la Comunidad. Las **administraciones** (la Comunidad, los ayuntamientos y las agencias de desarrollo local) necesitan saber qué municipios necesitan actividad, cuáles pueden atraerla y qué la frena. Ambos perfiles trabajan sobre los mismos datos públicos y los mismos modelos. La aplicación está publicada en **madrid179.web.app** y el código es abierto (licencia MIT).

1. Enfoque general

El sistema combina **dos modelos únicos para toda la región**, entrenados sobre los mismos 179 municipios; no hay un modelo por municipio. Un **GA²M** (modelo aditivo explicable con interacciones por pares) da la puntuación, porque es el que mejor ordena. Una **red bayesiana** no puntúa: explica cada resultado, responde consultas con información parcial y sostendrá el simulador de políticas. La puntuación de cada municipio es:

$$S = \text{percentil del GA}^2\text{M entre los municipios candidatos (0-100)}$$

$$\text{Puntuación} = (S + \Sigma\, a_k \cdot u_k) \,/\, (1 + \Sigma\, a_k)$$

u_k: utilidad del municipio en la preferencia k (0-1)

$$a_k = r \cdot \text{sd}(S) \,/\, \text{sd}(u_k) \cdot r = 0 \,/\, 0{,}5 \,/\, 1 \cdot \Sigma\, a_k \le 3$$

Las restricciones se separan en dos tipos para que los modelos nunca reciban condiciones imposibles:

- **Filtros duros.** Siempre: Madrid capital no es candidata (es la referencia del reequilibrio) y se exige al menos un local de oficinas en el Catastro (139 candidatos). El usuario puede añadir 7 más marcando algo como imprescindible: estación a menos de cierta distancia, distancia a Madrid mínima o máxima, población mínima o máxima, coworking o poder optar a ayudas. Se aplican antes de puntuar; los municipios descartados se muestran aparte en el mapa.
- **Preferencias** (15). Factores que se ponderan sin descartar territorio: tren, transporte público, distancia a Madrid, coste, ayudas, talento, mano de obra, juventud, tamaño, renta, servicios profesionales, crecimiento, oficinas, coworking y servicios para la plantilla. «Muy importante» pesa tanto como el modelo y «poco importante» la mitad; con todas sumadas, el modelo pesa siempre al menos una cuarta parte. Cada preferencia se muestra por separado en la explicación.

2. Arquitectura

Capa	Tecnología	Motivo
Aplicación web	React y TypeScript (Vite), servida por la propia API en madrid179.web.app	Sin instalación; versión de escritorio y de móvil con la misma base de código
Mapa 3D	MapLibre con deck.gl (WebGL)	Los 179 municipios como columnas por grupo de puntuación, con transiciones al cambiar preferencias
Motores de modelo	Python, FastAPI (API /api/v1), pgmpy (red bayesiana) e InterpretML (GA²M)	Un artefacto entrenado se carga en memoria; la API no reentrena y responde en milisegundos
Datos	Tablas CSV con clave INE, artefacto del modelo y GeoJSON de límites municipales	179 filas y datos anuales: no hace falta un gestor de base de datos
Asistente	LLM (DeepSeek, salidas JSON) con saneado contra el catálogo y verificador en código	Traduce la descripción del negocio a preferencias y filtros, y redacta un resumen ceñido a los datos de la ficha
Despliegue	Contenedor en Cloud Run (Madrid) tras Firebase Hosting; CI con tests en GitHub Actions	Coste mínimo en reposo; los tests comprueban que el artefacto reproduce los resultados versionados

3. Datos y origen de cada variable

Todas las fuentes son públicas y se unen por código INE municipal, sección censal o coordenadas. La mayoría llega a través del portal de datos abiertos de la Comunidad de Madrid (datos.comunidad.madrid), donde el Instituto de Estadística de la Comunidad de Madrid (IECM) republica estadísticas de otros organismos. Por eso la tabla distingue la **fuente primaria**, que produce el dato, de quién lo **publica** y en qué conjunto de datos.

Variable y uso	Indicador	Fuente primaria	Publicado en · conjunto	Año
Viabilidad Empresarial (objetivo)	Tasa neta de unidades productivas: (nacen + entran − mueren − salen) / activas	Dinámica Empresarial · Dirección General de Economía e Industria (CAM)	IECM · din_emp	2020-24
Dinamismo Demográfico · Densidad	Crecimiento de la población empadronada en 5 años; habitantes por km²	Padrón municipal · INE	IECM · padron_por_sexo	2020-25
Juventud	% de población menor de 45 años	Padrón municipal · INE	IECM · grado_juventud_por_edad	2025
Talento	% de población de 15 y más años con estudios superiores	Censo de Población anual · INE	IECM · poblacion_censada_por_estudios_y_sexo	2024
Renta	Renta disponible bruta per cápita	Indicador de Renta Disponible Bruta Municipal · INE	IECM · irpf_indicador_renta	2023
Paro	Paro registrado por 100 habitantes	Servicio Público de Empleo (CAM)	IECM · 1902280	2025
Especialización Servicios	% de unidades productivas en información y servicios profesionales	Colectivo Empresarial · Dirección General de Economía e Industria (CAM)	IECM · col_emp_ramas	2025
Coste Inmobiliario	Valor catastral residencial medio por unidad urbana	Catastro Inmobiliario · Dirección General del Catastro	IECM · 1002054	2026
GA²M y filtro: oferta de oficinas	Unidades urbanas de uso oficinas (total y por 1.000 hab.)	Catastro Inmobiliario · Dirección General del Catastro	IECM · unidades_urbanas_por_uso	2026
Distancia Madrid	Km del centroide municipal a la Puerta del Sol	Cálculo propio sobre el seccionado censal	Comunidad de Madrid · secciones_censales	2019
Acceso Ferroviario · distancia a estación	Estaciones de Metro, Metro Ligero y Cercanías	Consorcio Regional de Transportes de Madrid (GTFS)	Portal de datos abiertos del CRTM	2026
Sanidad · servicios para la plantilla	Sanidad, restauración, gimnasios, guarderías, coworking, deporte	OpenStreetMap (licencia ODbL)	Overpass API	2026
Ayudas oficiales (fuera del modelo)	Municipios de los grupos LEADER 2023-2027; reglas para menos de 2.500 hab.	Convenios con los tres grupos de acción local (anexo I) · Ley 5/2024 (deducciones del IRPF)	BOCM 18-01-2025 · padrón (INE)	2025

IECM: Instituto de Estadística de la Comunidad de Madrid. Los conjuntos se identifican por su nombre en el portal de datos abiertos (datos.comunidad.madrid/catalogo/dataset/<nombre>). Las ayudas oficiales no entran en ningún modelo: se muestran como información, como preferencia o como filtro. El anexo de fuentes amplía las fuentes previstas y privadas.

La canalización construida:

- **Recolección automatizada** de los catálogos de datos abiertos de la Comunidad y del Ayuntamiento de Madrid (2.263 y 674 conjuntos), con descarga de 621 tablas municipales, los edificios del Catastro de los 179 municipios, las redes GTFS del Consorcio de Transportes y 153.517 puntos de interés de OpenStreetMap.
- **Normalización territorial:** cada tabla recibe el código INE de 5 dígitos a partir de un maestro de 179 municipios, con corrección de codificaciones y variantes de nombre. Paradas y puntos de interés se asignan a su sección censal por intersección espacial.
- **Tabla analítica única:** 179 municipios sin valores nulos, con unas 40 variables de demografía, renta, talento, empleo, tejido empresarial, coste inmobiliario, accesibilidad y servicios.

Variable objetivo. En municipios muy pequeños la tasa neta empresarial es muy ruidosa (pocas unidades productivas), así que se acerca a la media regional en proporción inversa a su tamaño (contracción empírico-bayesiana). Esa contracción favorece en parte a los municipios grandes y densos; se tiene en cuenta al leer el peso de la densidad y la población.

4. Modelos: red bayesiana y GA²M

La red tiene **12 nodos y 17 aristas**, con un máximo de dos padres cada uno, para que sus tablas de probabilidad sean pequeñas y estén bien estimadas con 179 municipios. Cada variable continua se discretiza en terciles de su distribución real (unos 60 municipios por estado), salvo el acceso ferroviario, que es binario. Los padres de los cuatro nodos añadidos en la versión 2 (densidad, juventud, sanidad y paro) se eligieron por puntuación BDeu local entre candidatos plausibles.

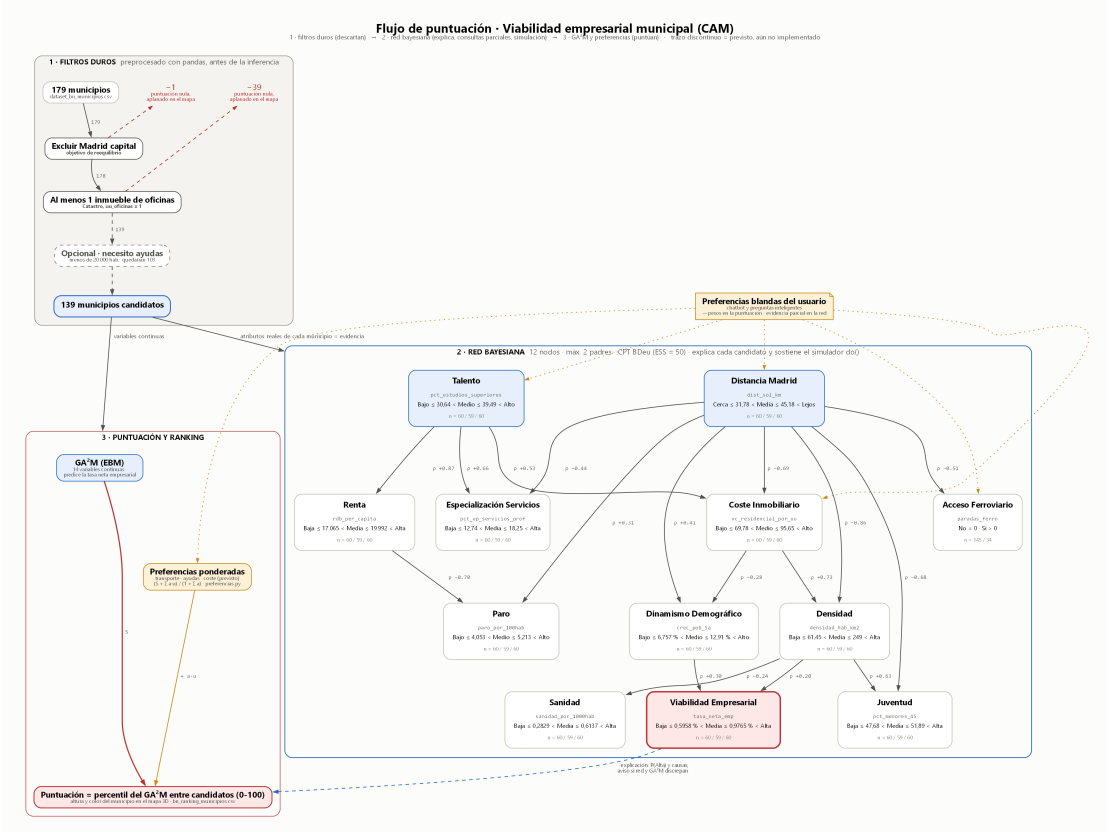


Figura 1. Flujo completo: filtros duros, red bayesiana y puntuación con el GA²M y las preferencias. Las etiquetas de las aristas de la red son correlaciones de Spearman entre las variables continuas, solo como referencia descriptiva.

Nodo	Variable	Padres	Cortes (p33 / p66)
Distancia Madrid	Distancia del centroide a la Puerta del Sol (km)	Raíz	31,8 / 45,2 km
Talento	% de población de 15 y más años con estudios superiores	Raíz	30,6 / 39,5 %
Acceso Ferroviario	Estaciones de Metro, Metro Ligero o Cercanías (GTFS CRTM)	Distancia	0 / más de 0
Coste Inmobiliario	Valor catastral residencial por unidad urbana (miles €)	Distancia, Talento	69,8 / 95,7
Renta	Renta disponible bruta per cápita (€)	Talento	17.065 / 19.992
Especialización Servicios	% de unidades productivas en información y servicios profesionales	Distancia, Talento	12,7 / 18,3 %
Dinamismo Demográfico	Crecimiento de la población en 5 años (padrón)	Distancia, Coste	6,8 / 12,9 %
Densidad	Habitantes por km²	Distancia, Coste	61 / 249
Juventud	% de población menor de 45 años	Distancia, Densidad	47,7 / 51,9 %

Nodo	Variable	Padres	Cortes (p33 / p66)
Sanidad	Centros sanitarios y farmacias por 1.000 hab. (OpenStreetMap)	Densidad	0,28 / 0,61
Paro	Paro registrado por 100 habitantes	Distancia, Renta	4,05 / 5,21
Viabilidad Empresarial	Tasa neta anual de unidades productivas 2020-2024 (objetivo)	Dinamismo, Densidad	0,60 / 0,98 %

Aprendizaje de la red. Las tablas de probabilidad se estiman con BayesianEstimator de pgmpy y prior BDeu (tamaño de muestra equivalente 50, elegido por validación cruzada) sobre los estados discretizados. La red supera check_model() y cada probabilidad se verifica a mano en el anexo de cálculo, que falla si la librería y el cálculo manual difieren.

GA²M. Explainable Boosting Machine de InterpretML sobre **14 variables** sin discretizar (las 11 de la red, la oferta de oficinas por habitante, la distancia a la estación y la población) y 10 interacciones, que predice la tasa neta empresarial. Es aditivo: la predicción es la suma de una curva por variable y de pocas interacciones, así que la puntuación de cada municipio se descompone exactamente en aportaciones. Se excluyen las variables con fuga de información (stock de unidades productivas y afiliados al final del periodo del objetivo).

Validación. Validación cruzada de 5 particiones repetida 5 veces, con predicciones fuera de muestra. Mide cómo de bien ordena cada modelo los municipios frente a su tasa neta real:

Modelo	Spearman con la realidad	Acierto en el tercio superior	Comentario
GA²M v2 (14 variables)	0,529 ± 0,03	64,3 %	Elegido para puntuar
GA²M v1 (7 variables)	0,398 ± 0,04	51,7 %	Versión anterior
Modelo lineal (7 variables)	0,383 ± 0,01	48,3 %	Referencia
Red bayesiana v2, P(Alta)	0,398	—	Explica; con evidencia completa solo da 9 niveles
Azar	0	33,5 %	—

La señal es real pero **moderada**. La red acierta el estado de viabilidad el 44,7 % de las veces (azar 33,3 %) y su log-loss medio (1,008 ± 0,015) ya mejora el de una distribución uniforme (1,099; la versión 1 no lo hacía), pero sus probabilidades siguen siendo aproximadas. Por eso la puntuación se presenta como posición relativa entre candidatos (percentil) y siempre como asociación, no como efecto causal. El transporte no mostró señal propia sobre el objetivo: entra como preferencia o filtro del usuario.

5. La aplicación

Tres modos comparten mapa, datos y modelos, y responden a preguntas distintas: la empresa busca dónde ir; la Administración busca dónde actuar.

5.1 «Dónde abrir» (empresas y emprendedores)

- **Asistente:** el usuario describe su negocio en texto libre. Un LLM solo lo traduce a preferencias y filtros del catálogo (JSON saneado contra el catálogo); la aplicación muestra lo que ha entendido y permite deshacerlo. También se puede ajustar cada preferencia a mano (me da igual, poco o muy importante, imprescindible).
- **Mapa 3D:** cada municipio es una columna con la altura y el color de su grupo (cinco quintiles, «no cumple tus requisitos» y «fuera del análisis»). Al cambiar una preferencia, las columnas se recolocan y un panel explica qué ha cambiado. Un recorrido guiado vuela por los mejores municipios.
- **Ficha:** factores a favor y en contra según el GA²M en tres niveles de fuerza, lectura de la red bayesiana, perfil en terciles, ayudas oficiales que alcanzan al municipio y un resumen «En pocas palabras» redactado por el LLM. Un verificador en código comprueba que cada frase cite datos de la ficha, que las cifras coincidan y que no haya lenguaje causal; lo que no pasa la revisión se descarta. Si la red y el GA²M discrepan, se avisa.

5.2 «Dónde actuar» (Administración)

Pensado para la dirección general responsable del reequilibrio territorial, la consejería de economía y empleo y los ayuntamientos y agencias de desarrollo local. Cubre 178 municipios (Madrid capital es la referencia).

- **Ámbito:** tramo de población, distancia a Madrid, municipios sin oficinas o municipios en LEADER.

- **Diagnóstico en cuatro grupos:** necesidad de reequilibrio (media de percentiles de crecimiento de población bajo, pocos menores de 45 años, paro alto y población pequeña) frente a viabilidad (percentil del GA²M). Resultado: necesita actividad y puede atraerla (33), necesita actividad y le cuesta atraerla (56), va por su cuenta (57) y sin urgencia, con poca viabilidad (32).
- **Frenos:** las aportaciones negativas del GA²M de cada municipio, marcadas como palanca (algo que una política puede mover a medio plazo, como la especialización o la oferta de oficinas) o estructural. El resultado es revelador: el modelo atribuye casi todo a factores estructurales (crecimiento, densidad, distancia).
- **Contexto para la política**, separado del modelo: oficinas en el Catastro (39 municipios sin ningún local), coworking y programas oficiales (LEADER, deducciones del IRPF y PIR sin cofinanciación para menos de 2.500 habitantes).
- **Escenarios** (en desarrollo): intervención do() sobre la red con su intervalo de incertidumbre, presentada siempre como escenario según el modelo y no como predicción.

5.3 «Explorar perfiles»

Consulta a la red bayesiana con información parcial (por ejemplo, «lejos de Madrid y con talento alto»): devuelve la probabilidad de cada nivel de viabilidad y resalta en el mapa los municipios que encajan.

Ejemplo de ficha: Buitrago del Lozoya

Cabecera comarcal de la Sierra Norte (2.034 habitantes, a 64 km de Madrid). Ocupa el puesto 126 de 139 candidatos (puntuación 10,1). Según el GA²M, su principal freno es el **escaso crecimiento de población** (−0,31 puntos de tasa neta empresarial al año), seguido del **valor de la vivienda**, que el modelo lee como señal de demanda (−0,09), de la densidad (−0,05) y del nivel formativo (−0,04). La distancia a Madrid, en cambio, le suma (+0,15). La red coincide: Dinamismo Bajo y Densidad Media, con P(Viabilidad Alta) = 0,22 y P(Baja) = 0,56. En «Dónde actuar» queda en el grupo «necesita actividad y le cuesta atraerla», con frenos estructurales. Lectura para el técnico: las políticas que atraigan población (vivienda, servicios) probablemente rindan más aquí que las ayudas directas a la empresa. Está en el grupo LEADER GALSINMA (Sierra Norte) y, por tener menos de 2.500 habitantes, quien se traslade puede optar a las deducciones del IRPF.

6. Valor para la Administración

La herramienta da a la Administración una vista común, basada en datos públicos y auditable, para decidir dónde y cómo actuar. Estas son las preguntas que responde y su estado actual:

Pregunta	Cómo la responde	Estado
¿Dónde me conviene abrir una oficina?	«Dónde abrir»: ranking del GA²M ajustado por las preferencias y filtros del usuario	Disponible
¿Qué favorece y qué frena a un municipio?	Ficha: aportación de cada factor (GA²M), lectura de la red bayesiana y ayudas que le alcanzan	Disponible
¿Qué municipios necesitan actividad y cuáles pueden atraerla?	«Dónde actuar»: necesidad de reequilibrio frente a viabilidad, en cuatro grupos, con frenos y contexto	Disponible
¿Qué municipios encajan con un perfil?	«Explorar perfiles»: consulta a la red con información parcial	Disponible
¿Cuánto reequilibrio produce una recomendación?	Peso de municipios pequeños y en LEADER en el top del ranking, con y sin preferencias	Disponible
¿Qué pasaría si se bonifica el alquiler o se crea un vivero?	Simulador: intervención do() sobre la palanca del modelo, con intervalo de incertidumbre	En desarrollo

Indicador de reequilibrio. Sirve para medir si una recomendación contribuye al objetivo territorial. De los 139 municipios candidatos, 103 (74 %) tienen menos de 20.000 habitantes y 33 menos de 2.500. Sin preferencias, el top 20 incluye 13 de menos de 20.000 (65 %), 1 de menos de 2.500 y 8 en LEADER: el modelo, por sí solo, da algo más de peso a municipios medianos y grandes en expansión. Si la empresa marca «Poder optar a ayudas» como poco importante, el top 20 pasa a 17, 2 y 16; como muy importante, los 20 son de menos de 20.000 habitantes y están en LEADER, y 5 tienen menos de 2.500. Las ayudas son una palanca eficaz de reequilibrio, y por eso su peso tiene un tope: el modelo nunca pesa menos de una cuarta parte.

Transparencia y rendición de cuentas. Toda probabilidad de la red se puede rehacer a mano a partir de conteos de municipios (anexo de cálculo, verificado automáticamente frente a la librería) y toda puntuación del GA²M se descompone en aportaciones exactas. Los datos son públicos y citables, el código es abierto y la API es pública. Esto permite justificar decisiones de inversión pública con un razonamiento que cualquiera puede revisar.

7. Limitaciones y siguientes pasos

- **Señal moderada.** El modelo ordena claramente mejor que el azar, pero no predice el éxito de una empresa concreta. Son asociaciones observadas en 2020-2024, no efectos causales.
- **Simulador de políticas.** Diseñado y prototipado, pero antes de ofrecerlo necesita monotonía completa en la tabla del objetivo (queda una violación, por escasez de datos en una casilla) e intervalos de incertidumbre por remuestreo.
- **Necesidad de reequilibrio.** Su definición es provisional: hoy correlaciona mucho con el tamaño ($\rho = -0{,}66$ con la población), así que los grupos de necesidad alta se llenan de pueblos muy pequeños. Sus variables y pesos deben validarse con técnicos de la Comunidad.
- **Ayudas.** Integradas las listas oficiales de LEADER y las reglas para menos de 2.500 habitantes. Faltan Pueblos con Vida, las ayudas estatales al reto demográfico y las convocatorias vigentes por perfil de negocio (Base de Datos Nacional de Subvenciones, ya descargada pero sin integrar).
- **Coste de oficinas.** El coste inmobiliario es un indicador residencial. Las rentas de oficinas, de acceso privado, la superficie de oficinas del Catastro y la cobertura de fibra y 5G mejorarían el modelo.
- **Validación con técnicos de la Comunidad de Madrid** del grafo, los umbrales, los textos de la ficha y los pesos de las preferencias.