

Cómo se calculan las probabilidades de la red bayesiana

Cada probabilidad del modelo sale de contar municipios reales. Este anexo muestra el procedimiento, todas las tablas con sus conteos y la verificación independiente frente a la librería pgmpy. El fichero auditoria_cpts.xlsx contiene los mismos cálculos, con la tabla de los 179 municipios discretizados, para reproducirlos en una hoja de cálculo.

1. Procedimiento

1. **Discretizar.** Cada variable continua se divide en tres estados por sus terciles (unos 60 municipios por estado); el acceso ferroviario es Sí o No. Cada municipio queda descrito por ocho etiquetas.
2. **Contar.** Para cada nodo se cuentan los municipios en cada estado, separados por cada combinación de estados de sus padres.
3. **Suavizar (prior BDeu).** Se suma a cada casilla un pseudo-conteo igual, para que ninguna probabilidad sea 0 por falta de datos. Equivale a añadir 10 municipios imaginarios repartidos de forma uniforme en cada tabla.
4. **Combinar.** La puntuación de un municipio es $P(\text{Viabilidad} = \text{Alta} \mid \text{evidencia})$, que se obtiene multiplicando las tablas (regla de la cadena) y sumando sobre lo que no se conoce.

$$\text{pseudo-conteo } \alpha = \text{ESS} / (\text{combinaciones de padres} \times \text{estados})$$

$$P(\text{estado} \mid \text{padres}) = (\text{conteo} + \alpha) / (\text{municipios con esos padres} + \text{estados} \times \alpha)$$

2. Ejemplo resuelto

Nodo objetivo **Viabilidad Empresarial**, con padres Dinamismo Demográfico y Especialización en Servicios: 9 combinaciones $\times$ 3 estados, así que $\alpha = 10 / 27 = 0,3704$. Entre los 24 municipios con Dinamismo Alto y Especialización Alta, 14 tienen viabilidad Alta, 3 Media y 7 Baja.

$$P(\text{Alta}) = (14 + 0,3704) / (24 + 3 \times 0,3704) = 0,5723$$

$$P(\text{Media}) = (3 + 0,3704) / (24 + 3 \times 0,3704) = 0,1342$$

$$P(\text{Baja}) = (7 + 0,3704) / (24 + 3 \times 0,3704) = 0,2935$$

Sin suavizar sería $14/24 = 0,5833$. Con más municipios en una combinación, el suavizado pesa menos.

3. Verificación independiente

Las tablas se recalcularon con pandas, sin pgmpy, y se compararon celda a celda con las que estima pgmpy (BayesianEstimator, prior BDeu, ESS = 10). Las inferencias se reprodujeron sumando la distribución conjunta completa, combinación por combinación, y se compararon con el algoritmo de eliminación de variables de pgmpy.

Nodo	Padres	Celdas	α	Diferencia máxima	Resultado
Distancia Madrid	(raíz)	3	3,3333	0.0e+00	Coincide
Talento	(raíz)	3	3,3333	0.0e+00	Coincide
Acceso Ferroviario	Distancia Madrid	6	1,6667	1.1e-16	Coincide
Coste Inmobiliario	Distancia Madrid, Talento	27	0,3704	0.0e+00	Coincide
Renta	Talento	9	1,1111	1.1e-16	Coincide
Especialización Servicios	Distancia Madrid, Talento	27	0,3704	0.0e+00	Coincide
Dinamismo Demográfico	Coste Inmobiliario, Distancia Madrid	27	0,3704	0.0e+00	Coincide
Viabilidad Empresarial	Dinamismo Demográfico, Especialización Servicios	27	0,3704	0.0e+00	Coincide

Consulta	Combinaciones sumadas	P(Alta) a mano	P(Alta) pgmpy	Diferencia
Sin evidencia (probabilidad a priori)	4.374	0,3270	0,3270	8.3e-16
Preferencia: Talento = Alto	1.458	0,3818	0,3818	5.6e-17
Preferencias: Coste = Bajo y Acceso ferroviario = Sí	729	0,3133	0,3133	3.3e-16
Municipio completo: Colmenar Viejo (28045)	3	0,5723	0,5723	0.0e+00

Diferencias del orden de 10^{-16} son redondeo de coma flotante: los cálculos son idénticos.

Colmenar Viejo tiene todos sus atributos observados, así que su puntuación es directamente la fila de la tabla del objetivo para Dinamismo Alto y Especialización Alta: 57,2 sobre 100.

4. Todas las tablas de probabilidad

Para cada combinación de padres: municipios que la cumplen (n), cuántos hay en cada estado del nodo y la probabilidad resultante tras el suavizado (columnas sombreadas).

Distancia Madrid (nodo raíz)

$$\alpha = 10 / (1 \times 3) = 3,3333$$

n	n Cerca	n Media	n Lejos	P(Cerca)	P(Media)	P(Lejos)
179	60	59	60	0,3351	0,3298	0,3351

Talento (nodo raíz)

$$\alpha = 10 / (1 \times 3) = 3,3333$$

n	n Bajo	n Medio	n Alto	P(Bajo)	P(Medio)	P(Alto)
179	60	59	60	0,3351	0,3298	0,3351

Acceso Ferroviario | Distancia Madrid

$$\alpha = 10 / (3 \times 2) = 1,6667$$

Distancia Madrid	n	n No	n Si	P(No)	P(Si)
Cerca	60	33	27	0,5474	0,4526
Media	59	55	4	0,9091	0,0909
Lejos	60	57	3	0,9263	0,0737

Coste Inmobiliario | Distancia Madrid, Talento

$$\alpha = 10 / (9 \times 3) = 0,3704$$

Distancia Madrid	Talento	n	n Bajo	n Medio	n Alto	P(Bajo)	P(Medio)	P(Alto)
Cerca	Bajo	19	4	12	3	0,2173	0,6151	0,1676
Cerca	Medio	15	1	3	11	0,0851	0,2092	0,7057
Cerca	Alto	26	0	2	24	0,0137	0,0874	0,8989
Media	Bajo	20	11	9	0	0,5386	0,4439	0,0175
Media	Medio	20	3	12	5	0,1596	0,5860	0,2544
Media	Alto	19	0	6	13	0,0184	0,3168	0,6648
Lejos	Bajo	21	17	4	0	0,7856	0,1977	0,0168
Lejos	Medio	24	13	9	2	0,5324	0,3732	0,0944
Lejos	Alto	15	11	2	2	0,7057	0,1471	0,1471

Renta | Talento

$$\alpha = 10 / (3 \times 3) = 1,1111$$

Talento	n	n Baja	n Media	n Alta	P(Baja)	P(Media)	P(Alta)
Bajo	60	48	11	1	0,7754	0,1912	0,0333
Medio	59	12	37	10	0,2103	0,6114	0,1783
Alto	60	0	11	49	0,0175	0,1912	0,7912

Especialización Servicios | Distancia Madrid, Talento

$$\alpha = 10 / (9 \times 3) = 0,3704$$

Distancia Madrid	Talento	n	n Baja	n Media	n Alta	P(Baja)	P(Media)	P(Alta)
Cerca	Bajo	19	8	11	0	0,4162	0,5654	0,0184
Cerca	Medio	15	2	12	1	0,1471	0,7678	0,0851
Cerca	Alto	26	0	1	25	0,0137	0,0505	0,9358
Media	Bajo	20	13	3	4	0,6333	0,1596	0,2070
Media	Medio	20	1	12	7	0,0649	0,5860	0,3491
Media	Alto	19	1	2	16	0,0681	0,1179	0,8140
Lejos	Bajo	21	17	3	1	0,7856	0,1524	0,0620
Lejos	Medio	24	11	11	2	0,4528	0,4528	0,0944
Lejos	Alto	15	7	4	4	0,4575	0,2713	0,2713

Dinamismo Demográfico | Coste Inmobiliario, Distancia Madrid

$$\alpha = 10 / (9 \times 3) = 0,3704$$

Coste Inmobiliario	Distancia Madrid	n	n Bajo	n Medio	n Alto	P(Bajo)	P(Media)	P(Alto)
Bajo	Cerca	5	2	3	0	0,3879	0,5515	0,0606
Bajo	Media	14	1	7	6	0,0907	0,4877	0,4216
Bajo	Lejos	41	9	9	23	0,2225	0,2225	0,5550
Medio	Cerca	17	11	6	0	0,6278	0,3517	0,0204
Medio	Media	27	5	13	9	0,1910	0,4756	0,3333
Medio	Lejos	15	5	5	5	0,3333	0,3333	0,3333
Alto	Cerca	38	22	7	9	0,5720	0,1884	0,2396
Alto	Media	18	4	7	7	0,2287	0,3857	0,3857
Alto	Lejos	4	1	2	1	0,2681	0,4638	0,2681

Viabilidad Empresarial | Dinamismo Demográfico, Especialización Servicios

$$\alpha = 10 / (9 \times 3) = 0,3704$$

Dinamismo Demográfico	Especialización Servicios	n	n Baja	n Media	n Alta	P(Baja)	P(Media)	P(Alta)
Bajo	Baja	16	12	3	1	0,7229	0,1970	0,0801
Bajo	Media	22	12	6	4	0,5353	0,2756	0,1891
Bajo	Alta	22	4	13	5	0,1891	0,5785	0,2324
Medio	Baja	19	6	7	6	0,3168	0,3665	0,3168
Medio	Media	26	6	8	12	0,2350	0,3087	0,4563
Medio	Alta	14	1	5	8	0,0907	0,3554	0,5539
Alto	Baja	25	8	10	7	0,3206	0,3972	0,2823
Alto	Media	11	4	4	3	0,3609	0,3609	0,2783
Alto	Alta	24	7	3	14	0,2935	0,1342	0,5723

Reproducir: `python backend/pipeline/auditoria_cpts.py`. El script falla si alguna probabilidad calculada a mano difiere de pgmpy.